

UNIVERSIDADE
POLITÉCNICA
DO CÁVADO
E DO AVE

CLAY SENSE ETL

Pipeline de Integração de Dados e Eficiência na Indústria Cerâmica

Licenciatura em Engenharia de Sistemas Informáticos

Integração de Sistemas de Informação

Rogério Picas 18395

Índice

Índice de Imagens 3
1. Enquadramento 4
2. Problema 4
3. Estratégia utilizada 4
3.1. Arquitetura IoT e Emulação de Telemetria (Node-RED & MQTT) 6
3.2. Fluxo de Trabalho e Modelação de Dados 6
4. Transformações 8
4.1. Transformação de Preparação de Dados 8
4.2. Transformação do Modelo de Produção 9
5. Jobs 10
5.1. Data Staging Pipeline Job 10
5.2. Report Export Job 11
5.3. Main Job 13
6. Visualização Analítica com Grafana 15
7. Vídeo com demonstração (QR Code) 16
8. Conclusão e Trabalhos futuros 17
8. Referências bibliográficas utilizadas, incluindo referências web que tenham sido relevantes. 17

Índice de Imagens

Figura 1 - Diagrama de Base de Dados (ER)..... **Erro! Marcador não definido.**
Figura 2 - Diagrama de fluxo da Data Preparation Transformation..... 8
Figura 3 – Diagrama de fluxo da Production Model Transformation..... 9
Figura 4 - Diagrama de fluxo do Data Staging Job..... 10

1. Enquadramento

No âmbito da unidade curricular de integração de sistemas de informação no curso de engenharia de sistemas informáticos, seguiu-se a proposta da elaboração de um projeto prático com tema livre, de forma que este possibilite a aplicação das práticas abordadas nas aulas de forma a demonstrar o domínio de determinados processos e ferramentas. No seguimento deste enquadramento, de forma a explorar um tema de interesse, este relatório irá demonstrar o desenvolvimento de uma solução focada na vertente da indústria cerâmica. O projeto ClaySense foi concebido para resolver uma lacuna tecnológica crítica no setor cerâmico artesanal e semi-industrial.

2. Problema

O presente relatório descreve o desenvolvimento de uma solução de integração e cruzamento de dados aplicada à indústria cerâmica. Embora existam no mercado plataformas consolidadas de apoio à gestão industrial, a sua adoção no setor cerâmico em pequenas olarias é praticamente nulo. As faltas de investimento em soluções modernas representam uma barreira crítica à transformação digital deste subsetor tradicional. Em consequência, o controlo térmico das fornadas e a gestão financeira dos ciclos de produção continuam dependentes de práticas predominantemente tradicionais.

Na tentativa de preencher esta lacuna, concebeu-se uma arquitetura capaz de correlacionar, de forma automatizada, a telemetria operacional dos fornos industriais com os lotes de fabrico e as respetivas especificações das pastas cerâmicas (nomeadamente as curvas e limites de temperatura admissíveis). O sistema visa garantir maior rigor operacional e eficiência de custos, identificando anomalias térmicas durante cada ciclo de cozedura e calculando automaticamente os custos energéticos associados à queima de cada lote e peça acabada.

3. Estratégia utilizada

A estratégia de integração concebida assenta em três pilares fundamentais: a produção, o processo térmico e os custos energéticos. Estes domínios constituem os eixos centrais de cruzamento de dados do sistema:

- **Produção:** agrega os dados de fabrico de cada lote, incluindo tipologia de peças, operador responsável, quantidades produzidas e registo de quebras;
- **Forno:** monitoriza as condições físicas da queima, tais como temperaturas máximas atingidas, perfil de aquecimento, durações dos ciclos e volumes de gás consumidos;

- **Custos Energéticos:** consolida os consumos apurados com os tarifários reais do mercado de energia (gás natural), permitindo calcular o custo total de cada ciclo de queima e o custo unitário por peça acabada.

Para implementar esta arquitetura, foram selecionadas as seguintes ferramentas e tecnologias:

- **Pentaho Data Integration (PDI / Kettle):** plataforma de ETL responsável pela ingestão de ficheiros heterogéneos, validações sintáticas via expressões regulares, filtragem de exceções, cruzamento de fluxos em memória (*stream lookups*) e execução da lógica de cálculo de custos;
- **Node-RED & Eclipse Mosquitto (MQTT):** o Node-RED atua na emulação dos sensores IoT de dois fornos industriais, publicando mensagens térmicas contínuas num broker Mosquitto, o qual assegura a comunicação leve e assíncrona da telemetria;
- **PostgreSQL (NeonDB na Cloud):** sistema de gestão de base de dados relacional para persistência transacional dos dados normalizados de produção, histórico de queimas, custos e tabelas dedicadas de auditoria;
- **Grafana:** ferramenta de visualização analítica para disponibilização de painéis em tempo real com a evolução térmica dos fornos, taxas de quebra por lote e métricas financeiras de eficiência energética;
- **API / Tarifário Regulado de Energia (REN):** mecanismo de recolha das tarifas dinâmicas e parâmetros energéticos (preço do kWh e poder calorífico do gás), possibilitando o apuramento exato do custo real de cozedura por peça aprovada.

3.1. Arquitetura IoT e Emulação de Telemetria (Node-RED & MQTT)

Para reproduzir com fidelidade o comportamento operacional dos fornos industriais sem acesso direto a sensores físicos em linha de fábrica, implementou-se um fluxo de emulação no Node-RED articulado com o broker Eclipse Mosquitto (MQTT).

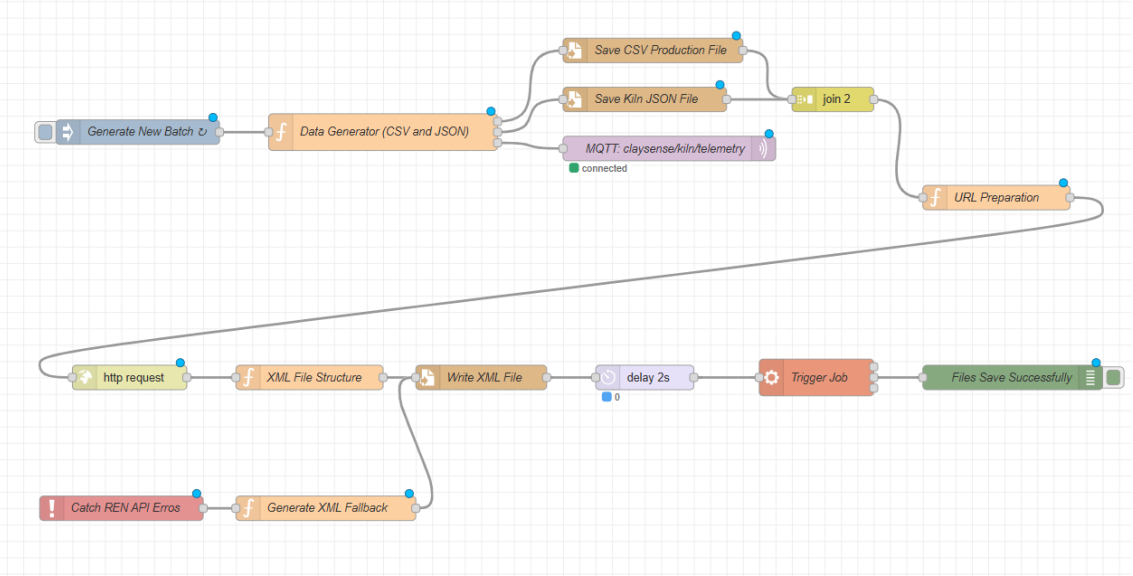


Figura 1 - Diagrama de fluxo do Node-RED

Como é possível observar na Figura 1, o fluxo inicia com a geração de dados de produção(CSV), e simultaneamente dados de telemetria dos fornos(JSON), acompanhada da respetiva publicação de dados via MQTT. Após a sincronização destas tarefas através de um join, o processo avança para a formatação e estruturação dos dados energéticos, efetuando um pedido HTTP à API da REN para apurar o preço real do kWh e do gás natural. Para garantir a resiliência do sistema, foi implementado um mecanismo de tolerância a falhas (Catch REN API Error) que assegura a geração de um ficheiro XML de contingência (fallback) caso o serviço externo se encontre indisponível. Uma vez concluída a formatação e escrita do XML, o fluxo introduz uma pausa técnica de dois segundos (delay 2s) destinada a assegurar a integridade das operações de gravação em disco (I/O). Por fim, o processo culmina no disparo automatizado do Main Job do Pentaho (Trigger Job), transferindo o controlo da operação para o motor de orquestração do pipeline ETL.

3.2. Fluxo de Trabalho e Modelação de Dados

No que concerne ao desenho da camada de persistência em PostgreSQL, a arquitetura inicial contemplava uma abordagem simplificada com apenas três tabelas centrais: production (registo de fabrico dos lotes), kiln (características físicas dos fornos) e batch_cost (métricas financeiras e consumos).

Contudo, a análise aprofundada da operação de produção revelou a necessidade de suportar uma relação de cardinalidade Muitos-para-Muitos (N:N) entre os fornos e os lotes cerâmicos, dado que um único ciclo de queima pode albergar simultaneamente múltiplos lotes de peças, tal como um mesmo lote pode, excecionalmente, ser processado em fornadas distintas.

Para garantir a normalização do esquema como é possível observar abaixo na Figura 2, introduziram-se duas entidades adicionais:



Figura 2 - Diagrama de Base de Dados (ER)

kiln_firing: entidade que isola o evento individual de cozedura, registando os identificadores do forno, os carimbos temporais, o perfil térmico e eventuais anomalias da queima;

firing_batch: tabela associativa que desagrega a relação N:N, articulando as chaves primárias de kiln_firing e production e mapeando a quantidade exata de peças alocada a cada cozedura (quantity_loaded).

Adicionalmente, concebeu-se a tabela log_rejections_audit com o propósito de auditar e rastrear todos os registos descartados nas etapas de validação e limpeza do pipeline ETL.

4. Transformações

No ecossistema do Pentaho PDI, as transformações representam a camada responsável pelo processamento de dados registo a registo, encarregando-se da sua extração, validação, enriquecimento e persistência na base de dados.

4.1. Transformação de Preparação de Dados

O processo de integração tem início na transformação de preparação de dados, responsável por orquestrar a ingestão paralela de três artefactos com origens e frequências distintas como é observável abaixo na Figura 3:

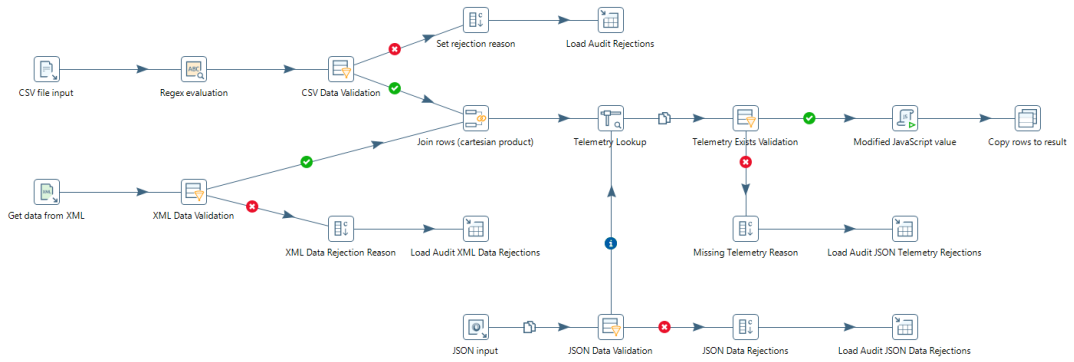


Figura 3 - Diagrama de fluxo da Data Preparation Transformation

Esta transformação tem como responsabilidade primária a extração e harmonização de três fontes de dados heterogéneas: um ficheiro CSV (registos de produção), um ficheiro XML (com parâmetros e tarifas energéticas provenientes da API da REN) e por fim um JSON (telemetria térmica IoT dos fornos). Antes de qualquer operação de fusão ou enriquecimento, cada fluxo é submetido a filtros de validação sintática via REGEX e semântica independentes, garantindo que registos malformados, valores físicos incoerentes ou lotes sem telemetria associada são imediatamente segregados para tabelas de auditoria, sem contaminar o modelo relacional de produção.

4.2. Transformação do Modelo de Produção

Concluída a fase de preparação e cálculo, foi desenvolvida a transformação do modelo de produção, cuja finalidade é consumir as linhas validadas em memória e persisti-las de forma estruturada na base de dados relacional.

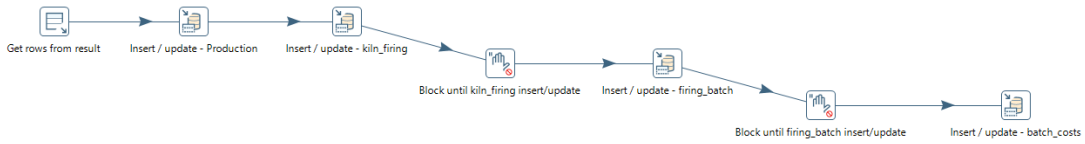


Figura 4 – Diagrama de fluxo da Production Model Transformation

Como é visível na Figura 4 ,esta transformação é responsável por mapear os atributos nas tabelas de destino dividindo os dados entre a produção dos lotes, o histórico térmico dos fornos, a associação das fornadas e os respetivos custos calculados, assegurando a ordem de inserção necessária para respeitar as restrições de integridade referencial.

5. Jobs

A camada de orquestração do ecossistema ClaySense é assegurada por três jobs modulares e hierárquicos: o Data Staging Pipeline Job (ingestão e persistência), o Report Export Job (inteligência analítica e alertas) e o Main Job, responsável por coordenar a execução global do pipeline.

5.1. Data Staging Pipeline Job

O job Data Staging Pipeline atua como o motor de orquestração técnica do sistema, sendo responsável por coordenar a sequência de execução das transformações e garantir que o pipeline opera sob um modelo defensivo. A sua função primordial consiste em validar a disponibilidade da base de dados e a integridade formal dos ficheiros de entrada antes do processamento. Em caso de anomalia, regista logs de erro especializados e interrompe imediatamente a execução; caso contrário, executa sequencialmente as transformações de preparação e carregamento e arquiva os ficheiros processados. Todos estes passos são visíveis abaixo na Figura 5.

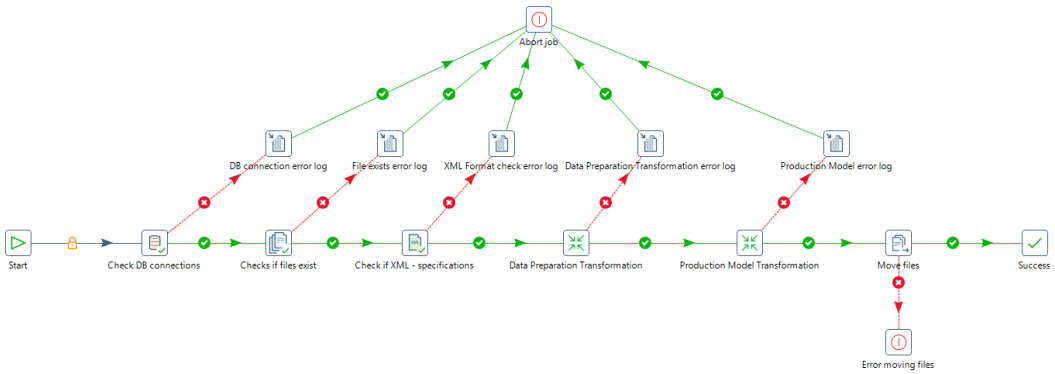


Figura 5 - Diagrama de fluxo do Data Staging Job

1. Pré-Validação de Ambiente e Infraestrutura:

- **Check DB connections**: Testa a conectividade à base de dados PostgreSQL (NeonDB na Cloud). Se o servidor estiver indisponível, gera o registo em DB connection error log e aborta o job (Abort job) sem ler qualquer ficheiro.
- **Checks if files exist**: Confirma a presença dos ficheiros de entrada necessários para a execução (.csv, .xml, .json) na pasta de *input*. Na ausência de ficheiros, desvia para File exists error log e depois Abort job.
- **Check if XML - specifications**: Valida a estrutura e conformidade do ficheiro de tarifas antes de iniciar a extração. Em caso de malformação sintática, gera o registo em XML Format check error log e por fim Abort job.

2. Execução Sequencial das Transformações de Dados:

- **Data Preparation Transformation**: Executa a primeira transformação (limpeza via Regex, segregação de auditoria em quatro ramos, *Stream lookup* via *Info Hop* e cálculo de custos/anomalias via JavaScript). Se ocorrer algum erro fatal, é gerado o registo em Data Preparation Transformation error log e por fim Abort job.
- **Production Model Transformation**: Consome os dados validados em memória (Get rows from result) e persiste os registos nas tabelas relacionais (production, kiln_firing, firing_batch e batch_costs) respeitando a integridade referencial. Em caso de falha de persistência, gera o Production Model error log e por fim Abort job.

3. Pós-Processamento e Isolamento de Staging:

- **Move files**: Uma vez concluído o carregamento com êxito, os ficheiros fonte processados são movidos para um diretório de arquivo histórico, prevenindo que sejam lidos repetidamente em execuções subsequentes. Se a movimentação falhar no sistema de ficheiros, é acionado o nó Error moving files.
- **Success**: Sinaliza o fecho com sucesso de todo o ciclo de preparação, inserção e rotação de dados.

5.2. Report Export Job

O job de exportação de relatórios (Report Export Job) é responsável pela fase final de inteligência operacional e comunicação do sistema, encarregando-se da geração analítica e distribuição automatizada de relatórios aos responsáveis da unidade de produção.

Este fluxo inicia-se com a execução da transformação de exportação (Report Export Transformation) e avalia dinamicamente os ficheiros gerados: caso sejam identificadas anomalias térmicas ou operacionais críticas, dispara um canal prioritário com aviso expresso por correio eletrónico; em condições de queima regulares, encaminha apenas o relatório geral de produção, procedendo em ambos os cenários ao arquivo seguro dos documentos emitidos e ao registo de eventuais falhas de comunicação.

Na seguinte Figura 6 podemos observar detalhadamente o fluxo de todo o Job de exportação de relatórios:

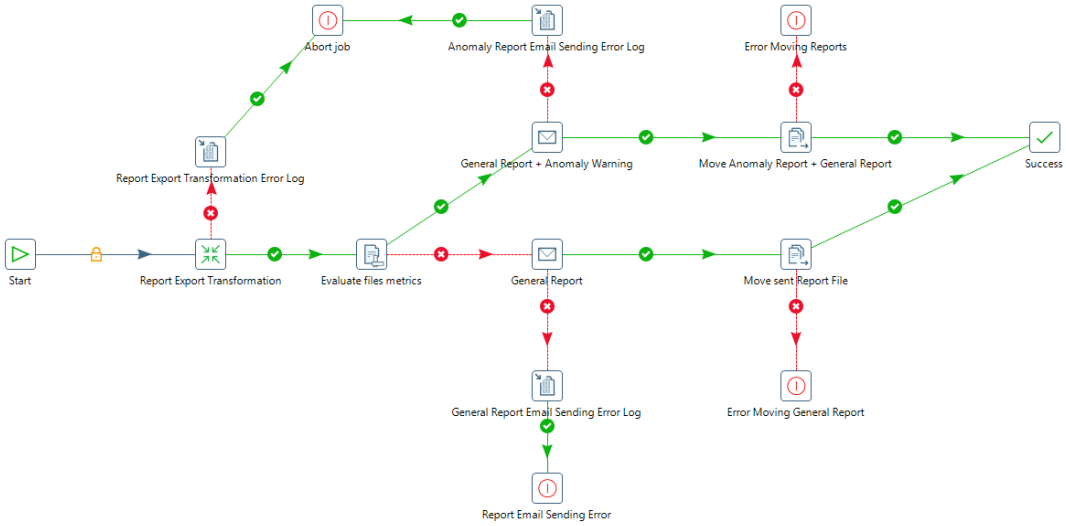


Figura 6 - Diagrama de fluxo Job de Exportação

1. Geração Analítica e Avaliação de Condições

- **Report Export Transformation**: Executa a transformação analítica que agrega os dados da base de dados e gera os ficheiros físicos de resumo de produção e métricas de queima. Em caso de falha de execução, o erro é desviado para Report Export Transformation Error Log e interrompe o processo no nó Abort job.
- **Evaluate files metrics**: Analisa as métricas presentes nos ficheiros gerados (avaliando, por exemplo, o tamanho, número de linhas ou indicadores de queima como excesso de quebras e violações de temperatura máxima) para decidir a rota de comunicação.

2. Ramo de Alerta de Anomalias (Caminho Verde / Sucesso na Condição):

- **General Report + Anomaly Warning**: Se forem apuradas anomalias térmicas ou de qualidade no ciclo de queima, este step de envio de correio eletrónico (SMTP) remete um e-mail de alerta, anexando tanto o relatório geral como o alerta detalhado de anomalias.
- **Move Anomaly Report + General Report**: Move com sucesso ambos os ficheiros para a pasta de histórico de relatórios enviados, finalizando no nó Success.
- *Tratamento de Exceções:* Falhas no envio de e-mail ativam o Anomaly Report Email Sending Error Log e depois Abort job, enquanto problemas na movimentação de ficheiros ativam o nó Error Moving Reports.

3. Ramo de Operação Normal (Caminho Vermelho / Falso na Condição):

- **General Report**: Caso não existam ocorrências críticas de anomalia, o sistema encaminha exclusivamente o relatório de produção geral e indicadores habituais de custos aos destinatários.
- **Move sent Report File**: Concluído o envio do correio eletrónico, o relatório expedido é transferido para o arquivo permanente, alcançando o nó Success.
- *Tratamento de Exceções:* Erros no envio acionam o General Report Email Sending Error Log e terminam no nó de paragem Report Email Sending Error; anomalias ao arquivar o relatório são sinalizadas pelo nó Error Moving General Report.

5.3. Main Job

O Main Job funciona como o ponto de entrada e orquestrador de topo de todo o ecossistema ClaySense, sendo o elemento disparado pelo agendador de tarefas (scheduler) da infraestrutura. A sua responsabilidade é coordenar sequencialmente os dois grandes blocos do sistema: em primeiro lugar, a ingestão, validação e persistência dos dados de produção através do sub-job Data Staging Pipeline; em segundo lugar, concluído o carregamento com sucesso, o processamento analítico e distribuição da informação no sub-job Generate Report. Operando segundo o princípio fail-fast, qualquer falha crítica num dos blocos desvia a execução para logs de diagnóstico dedicados e termina imediatamente o processo no nó Abort job, impedindo a criação de relatórios com dados inconsistentes ou desatualizados. Na seguinte Figura 7 é observável a simplicidade de um job principal:

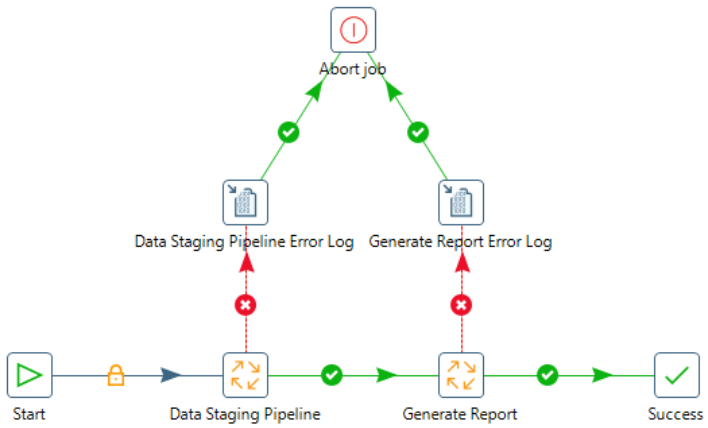


Figura 7 - Diagrama do fluxo - MainJob

Início e Execução do Ciclo de Dados (Start - Data Staging Pipeline):

- O job arranca no nó Start e executa como primeira tarefa o sub-job Data Staging Pipeline.
- É neste primeiro bloco que se validam as ligações ao PostgreSQL (NeonDB), a presença física dos ficheiros (CSV, XML, JSON) e se executam as duas transformações nucleares (Data Preparation e Production Model) com arquivo posterior dos ficheiros fonte.
- *Tratamento de Exceções:* Se o Data Staging Pipeline falhar (caminho vermelho com ×), o fluxo é intercetado pelo nó Data Staging Pipeline Error Log, que regista a falha de ingestão e encaminha para o Abort job, abortando o processo antes de tentar gerar relatórios sobre uma base de dados não atualizada.

2. Execução da Camada Analítica (Generate Report):

- Uma vez concluído o carregamento e arquivo de dados com êxito, o job avança para a chamada do sub-job Generate Report (que no diagrama detalhado corresponde ao Report Export Job).
- Este sub-job executa a transformação de agregação, avalia a ocorrência de anomalias térmicas e expede os e-mails com os relatórios devidos (aviso com anomalias ou relatório geral).
- *Tratamento de Exceções:* Se a extração analítica ou a comunicação SMTP falhar, o erro ativa o nó Generate Report Error Log e desvia igualmente para o Abort job.

3. Finalização Global (Success):

- O nó Success só é alcançado se ambos os sub-jobs completarem as respetivas tarefas sem qualquer exceção não tratada, confirmando que a base de dados de produção foi alimentada e que a gestão fabril foi notificada com sucesso

6.Visualização Analítica com Grafana

Para dotar a administração fabril e os responsáveis de produção de visibilidade em tempo real sobre a operação, configurou-se uma camada de visualização analítica através da plataforma **Grafana**, conectada diretamente à base de dados relacional PostgreSQL (NeonDB). O painel de controlo (*dashboard*) foi estruturado para consolidar os dados processados pelo pipeline ETL, permitindo correlacionar indicadores de produtividade, eficiência energética e estabilidade térmica dos fornos.

Seguem os seguintes links para visualização dos dashboards do Grafana:

- Main Dashboard: https://claysense.grafana.net/public-dashboards/0a6430ff0ae147e8b8e4455f1f19cdc8

- Dashboard de Anomalias e Custos https://claysense.grafana.net/public-dashboards/d7bf2601fa43473f8a0b97ed10a40943



Figura 8 - Preview do Main Dashboard no Grafana



Figura 9 - Preview do Dashboard de Fornos e Custos no Grafana

7.Vídeo com demonstração (QR Code)

8. Conclusão

O projeto ClaySense cumpriu o objetivo primordial de conceber e implementar uma arquitetura de integração de dados capaz de modernizar o controlo operacional na indústria cerâmica, colmatando a histórica dependência de métodos empíricos e tradicionais. Através da orquestração de um pipeline ETL robusto e tolerante a falhas no Pentaho Data Integration, suportado pela emulação IoT via Node-RED e MQTT, demonstrou-se a viabilidade de automatizar a recolha e o cruzamento da telemetria dos fornos com os registos de fabrico e os tarifários dinâmicos de energia. A centralização dos dados num modelo relacional normalizado em PostgreSQL, aliada à camada de inteligência analítica no Grafana, fornece à administração fabril indicadores rigorosos e imediatos sobre o rendimento de peças aprovadas, a estabilidade dos ciclos térmicos e o impacto financeiro de cada fornada.

Como perspetivas de desenvolvimento futuro, a evolução do sistema deverá contemplar a integração de modelos de *Machine Learning* para análise preditiva, permitindo antecipar anomalias de cozedura e otimizar as curvas de temperatura antes da ocorrência de quebras. Sugere-se igualmente a contentorização integral da infraestrutura (utilizando tecnologias como Docker) para garantir uma escalabilidade fluida em ambientes de produção industrial, bem como a expansão do módulo de notificações de anomalia para plataformas de mensagens instantâneas utilizadas diretamente pelos operadores de fábrica

8. Referências bibliográficas

- **Eclipse Foundation. (s.d.). *Eclipse Mosquitto: An open source MQTT broker*. Recuperado de https://mosquitto.org/**
- **Grafana Labs. (s.d.). *Grafana: The open observability platform*. Recuperado de https://grafana.com/**
- **Hitachi Vantara. (s.d.). *Pentaho Data Integration (Kettle)*. Recuperado de https://www.hitachivantara.com/**
- **Neon. (s.d.). *Neon: Serverless Postgres*. Recuperado de https://neon.tech/**
- **OpenJS Foundation. (s.d.). *Node-RED: Low-code programming for event-driven applications*. Recuperado de https://nodered.org/**
- **PostgreSQL Global Development Group. (s.d.). *PostgreSQL: The World's Most Advanced Open Source Relational Database*. Recuperado de https://www.postgresql.org/**
- **REN - Redes Energéticas Nacionais. (s.d.). *Dados do Sistema Elétrico e Gás Natural*. Recuperado de https://datahub.ren.pt/**