

UNIVERSIDADE
POLITÉCNICA
DO CÁVADO
E DO AVE

CLAY SENSE ETL

Pipeline de Integração de Dados e Eficiência na Indústria Cerâmica

Licenciatura em Engenharia de Sistemas Informáticos

Integração de Sistemas de Informação

Rogério Picas 18395

Índice

Índice de Imagens 2
1. Enquadramento 4
2. Problema 4
3. Estratégia utilizada 4
3.1. Arquitetura IoT e Emulação de Telemetria (Node-RED & MQTT) 5
3.2. Fluxo de Trabalho e Modelação de Dados 6
4. Transformações 7
4.1. Transformação de Preparação de Dados 8
4.2. Transformação do Modelo de Produção 8
5. Jobs 9
5.1. Data Staging Pipeline Job 10
5.2. Report Export Job 11
5.3. Main Job 13
6. Visualização Analítica com Grafana 15
Main Dashboard 15
Dashboard de Fornos, Custos & Energia 16
7. Vídeo com demonstração (QR Code) 17
8. Conclusão 17
8. Referências bibliográficas 18

Índice de Imagens

Figura 1 - Diagrama de fluxo do Node-RED 6
Figura 2 - Diagrama de Base de Dados (ER) 7
Figura 3 - Diagrama de fluxo da Data Preparation Transformation 8
Figura 4 – Diagrama de fluxo da Production Model Transformation 9
Figura 5 - Diagrama de fluxo do Data Staging Job 10
Figura 6 - Diagrama de fluxo Job de Exportação 12
Figura 7 - Diagrama do fluxo - MainJob 13
Figura 8 - Preview do Main Dashboard no Grafana 15
Figura 9 - Preview do Dashboard de Fornos e Custos no Grafana 16

1. Enquadramento

No âmbito da unidade curricular de integração de sistemas de informação no curso de engenharia de sistemas informáticos, seguiu-se a proposta da elaboração de um projeto prático com tema livre, de forma que este possibilite a aplicação das práticas abordadas nas aulas de forma a demonstrar o domínio de determinados processos e ferramentas. No seguimento deste enquadramento, de forma a explorar um tema de interesse, este relatório irá demonstrar o desenvolvimento de uma solução focada na vertente da indústria cerâmica. O projeto ClaySense foi concebido para resolver uma lacuna tecnológica crítica no setor cerâmico artesanal e semi-industrial.

2. Problema

O presente relatório descreve o desenvolvimento de uma solução de integração e cruzamento de dados aplicada à indústria cerâmica. Embora existam no mercado plataformas consolidadas de apoio à gestão industrial, a sua adoção no setor cerâmico em pequenas olarias é praticamente nulo. As faltas de investimento em soluções modernas representam uma barreira crítica à transformação digital deste subsetor tradicional. Em consequência, o controlo térmico das fornadas e a gestão financeira dos ciclos de produção continuam dependentes de práticas predominantemente tradicionais.

Na tentativa de preencher esta lacuna, concebeu-se uma arquitetura capaz de correlacionar, de forma automatizada, a telemetria operacional dos fornos industriais com os lotes de fabrico e as respetivas especificações das pastas cerâmicas (nomeadamente as curvas e limites de temperatura admissíveis). O sistema visa garantir maior rigor operacional e eficiência de custos, identificando anomalias térmicas durante cada ciclo de cozedura e calculando automaticamente os custos energéticos associados à queima de cada lote e peça acabada.

3. Estratégia utilizada

A estratégia de integração concebida assenta em três pilares fundamentais: a produção, o processo térmico e os custos energéticos. Estes domínios constituem os eixos centrais de cruzamento de dados do sistema:

- **Produção:** agrega os dados de fabrico de cada lote, incluindo tipologia de peças, operador responsável, quantidades produzidas e registo de quebras;
- **Forno:** monitoriza as condições físicas da queima, tais como temperaturas máximas atingidas, perfil de aquecimento, durações dos ciclos e volumes de gás consumidos;

- **Custos Energéticos:** consolida os consumos apurados com os tarifários reais do mercado de energia (gás natural), permitindo calcular o custo total de cada ciclo de queima e o custo unitário por peça acabada.

Para implementar esta arquitetura, foram selecionadas as seguintes ferramentas e tecnologias:

- **Pentaho Data Integration (PDI / Kettle):** plataforma de ETL responsável pela ingestão de ficheiros heterogéneos, validações sintáticas via expressões regulares, filtragem de exceções, cruzamento de fluxos em memória (*stream lookups*) e execução da lógica de cálculo de custos;
- **Node-RED & Eclipse Mosquitto (MQTT):** o Node-RED atua na emulação dos sensores IoT de dois fornos industriais, publicando mensagens térmicas contínuas num broker Mosquitto, o qual assegura a comunicação leve e assíncrona da telemetria;
- **PostgreSQL (NeonDB na Cloud):** sistema de gestão de base de dados relacional para persistência transacional dos dados normalizados de produção, histórico de queimas, custos e tabelas dedicadas de auditoria;
- **Grafana:** ferramenta de visualização analítica para disponibilização de painéis em tempo real com a evolução térmica dos fornos, taxas de quebra por lote e métricas financeiras de eficiência energética;
- **API / Tarifário Regulado de Energia (REN):** mecanismo de recolha das tarifas dinâmicas e parâmetros energéticos (preço do kWh e poder calorífico do gás), possibilitando o apuramento exato do custo real de cozedura por peça aprovada.

3.1. Arquitetura IoT e Emulação de Telemetria (Node-RED & MQTT)

Para reproduzir com fidelidade o comportamento operacional dos fornos industriais sem acesso direto a sensores físicos em linha de fábrica, implementou-se um fluxo de emulação no Node-RED articulado com o broker Eclipse Mosquitto (MQTT).

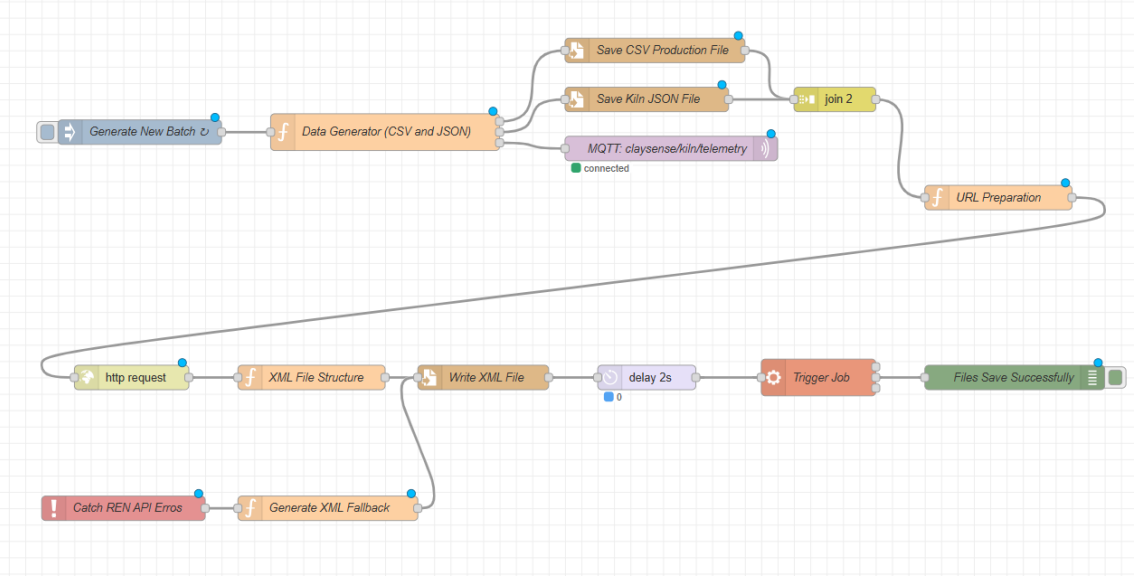


Figura 1 - Diagrama de fluxo do Node-RED

Como é possível observar na Figura 1, o fluxo inicia com a geração de dados de produção(CSV), e simultaneamente dados de telemetria dos fornos(JSON), acompanhada da respetiva publicação de dados via MQTT. Após a sincronização destas tarefas através de um join, o processo avança para a formatação e estruturação dos dados energéticos, efetuando um pedido HTTP à API da REN para apurar o preço real do kWh e do gás natural. Para garantir a resiliência do sistema, foi implementado um mecanismo de tolerância a falhas (Catch REN API Error) que assegura a geração de um ficheiro XML de contingência (fallback) caso o serviço externo se encontre indisponível. Uma vez concluída a formatação e escrita do XML, o fluxo introduz uma pausa técnica de dois segundos (delay 2s) destinada a assegurar a integridade das operações de gravação em disco (I/O). Por fim, o processo culmina no disparo automatizado do Main Job do Pentaho (Trigger Job), transferindo o controlo da operação para o motor de orquestração do pipeline ETL.

3.2. Fluxo de Trabalho e Modelação de Dados

No que concerne ao desenho da camada de persistência em PostgreSQL, a arquitetura inicial contemplava uma abordagem simplificada com apenas três tabelas centrais: production (registo de fabrico dos lotes), kiln (características físicas dos fornos) e batch_cost (métricas financeiras e consumos).

Contudo, a análise aprofundada da operação de produção revelou a necessidade de suportar uma relação de cardinalidade Muitos-para-Muitos (N:N) entre os fornos e os lotes cerâmicos, dado que um único ciclo de queima pode albergar simultaneamente múltiplos lotes de peças, tal como um mesmo lote pode, excecionalmente, ser processado em fornadas distintas.

Para garantir a normalização do esquema como é possível observar abaixo na Figura 2, introduziram-se duas entidades adicionais:



Figura 2 - Diagrama de Base de Dados (ER)

kiln_firing: entidade que isola o evento individual de cozedura, registando os identificadores do forno, os carimbos temporais, o perfil térmico e eventuais anomalias da queima;

firing_batch: tabela associativa que desagrega a relação N:N, articulando as chaves primárias de kiln_firing e production e mapeando a quantidade exata de peças alocada a cada cozedura (quantity_loaded).

Adicionalmente, concebeu-se a tabela log_rejections_audit com o propósito de auditar e rastrear todos os registos descartados nas etapas de validação e limpeza do pipeline ETL.

4. Transformações

No ecossistema do Pentaho PDI, as transformações representam a camada responsável pelo processamento de dados registo a registo, encarregando-se da sua extração, validação, enriquecimento e persistência na base de dados.

4.1. Transformação de Preparação de Dados

O processo de integração tem início na transformação de preparação de dados, responsável por orquestrar a ingestão paralela de três artefactos com origens e frequências distintas como é observável abaixo na Figura 3:

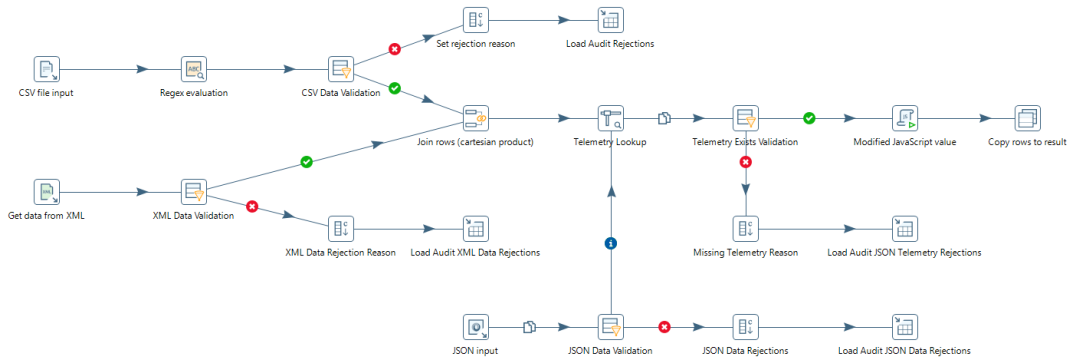


Figura 3 - Diagrama de fluxo da Data Preparation Transformation

Esta transformação tem como responsabilidade primária a extração e harmonização de três fontes de dados heterogéneas: um ficheiro CSV (registos de produção), um ficheiro XML (com parâmetros e tarifas energéticas provenientes da API da REN) e por fim um JSON (telemetria térmica IoT dos fornos). Antes de qualquer operação de fusão ou enriquecimento, cada fluxo é submetido a filtros de validação sintática via REGEX e semântica independentes, garantindo que registos malformados, valores físicos incoerentes ou lotes sem telemetria associada são imediatamente segregados para tabelas de auditoria, sem contaminar o modelo relacional de produção.

4.2. Transformação do Modelo de Produção

Concluída a fase de preparação e cálculo, foi desenvolvida a transformação do modelo de produção, cuja finalidade é consumir as linhas validadas em memória e persisti-las de forma estruturada na base de dados relacional.

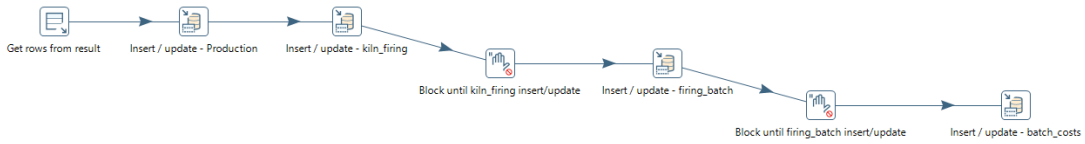


Figura 4 – Diagrama de fluxo da Production Model Transformation

Como é visível na Figura 4 ,esta transformação é responsável por mapear os atributos nas tabelas de destino dividindo os dados entre a produção dos lotes, o histórico térmico dos fornos, a associação das fornadas e os respetivos custos calculados, assegurando a ordem de inserção necessária para respeitar as restrições de integridade referencial.

5. Jobs

A camada de orquestração do ecossistema ClaySense é assegurada por três jobs modulares e hierárquicos: o Data Staging Pipeline Job (ingestão e persistência), o Report Export Job (inteligência analítica e alertas) e o Main Job, responsável por coordenar a execução global do pipeline.

5.1. Data Staging Pipeline Job

O job Data Staging Pipeline atua como o motor de orquestração técnica do sistema, sendo responsável por coordenar a sequência de execução das transformações e garantir que o pipeline opera sob um modelo defensivo. A sua função primordial consiste em validar a disponibilidade da base de dados e a integridade formal dos ficheiros de entrada antes do processamento. Em caso de anomalia, regista logs de erro especializados e interrompe imediatamente a execução; caso contrário, executa sequencialmente as transformações de preparação e carregamento e arquiva os ficheiros processados. Todos estes passos são visíveis abaixo na Figura 5.

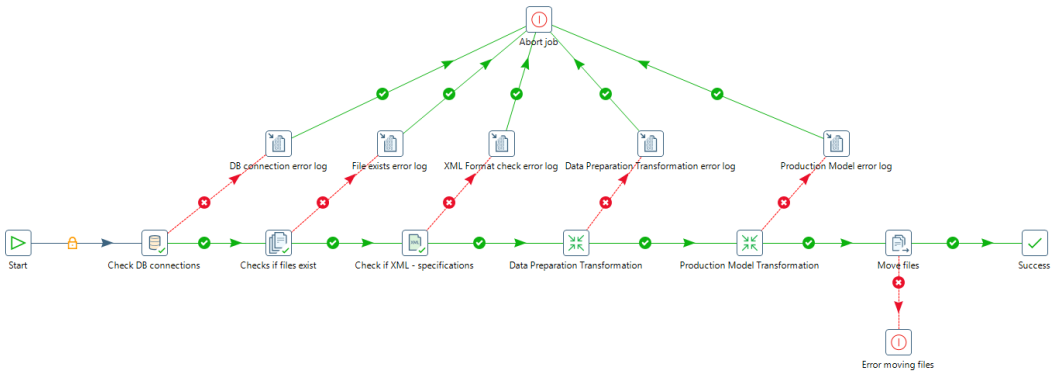


Figura 5 - Diagrama de fluxo do Data Staging Job

1. Pré-Validação de Ambiente e Infraestrutura:

- **Check DB connections**: Testa a conectividade à base de dados PostgreSQL (NeonDB na Cloud). Se o servidor estiver indisponível, gera o registo em DB connection error log e aborta o job (Abort job) sem ler qualquer ficheiro.
- **Checks if files exist**: Confirma a presença dos ficheiros de entrada necessários para a execução (.csv, .xml, .json) na pasta de *input*. Na ausência de ficheiros, desvia para File exists error log e depois Abort job.
- **Check if XML - specifications**: Valida a estrutura e conformidade do ficheiro de tarifas antes de iniciar a extração. Em caso de malformação sintática, gera o registo em XML Format check error log e por fim Abort job.

2. Execução Sequencial das Transformações de Dados:

- **Data Preparation Transformation**: Executa a primeira transformação (limpeza via Regex, segregação de auditoria em quatro ramos, *Stream lookup* via *Info Hop* e cálculo de custos/anomalias via JavaScript). Se ocorrer algum erro fatal, é gerado o registo em Data Preparation Transformation error log e por fim Abort job.
- **Production Model Transformation**: Consome os dados validados em memória (Get rows from result) e persiste os registos nas tabelas relacionais (production, kiln_firing, firing_batch e batch_costs) respeitando a integridade referencial. Em caso de falha de persistência, gera o Production Model error log e por fim Abort job.

3. Pós-Processamento e Isolamento de Staging:

- **Move files**: Uma vez concluído o carregamento com êxito, os ficheiros fonte processados são movidos para um diretório de arquivo histórico, prevenindo que sejam lidos repetidamente em execuções subsequentes. Se a movimentação falhar no sistema de ficheiros, é acionado o nó Error moving files.
- **Success**: Sinaliza o fecho com sucesso de todo o ciclo de preparação, inserção e rotação de dados.

5.2. Report Export Job

O job de exportação de relatórios (Report Export Job) é responsável pela fase final de inteligência operacional e comunicação do sistema, encarregando-se da geração analítica e distribuição automatizada de relatórios aos responsáveis da unidade de produção.

Este fluxo inicia-se com a execução da transformação de exportação (Report Export Transformation) e avalia dinamicamente os ficheiros gerados: caso sejam identificadas anomalias térmicas ou operacionais críticas, dispara um canal prioritário com aviso expresso por correio eletrónico; em condições de queima regulares, encaminha apenas o relatório geral de produção, procedendo em ambos os cenários ao arquivo seguro dos documentos emitidos e ao registo de eventuais falhas de comunicação.

Na seguinte Figura 6 podemos observar detalhadamente o fluxo de todo o Job de exportação de relatórios:

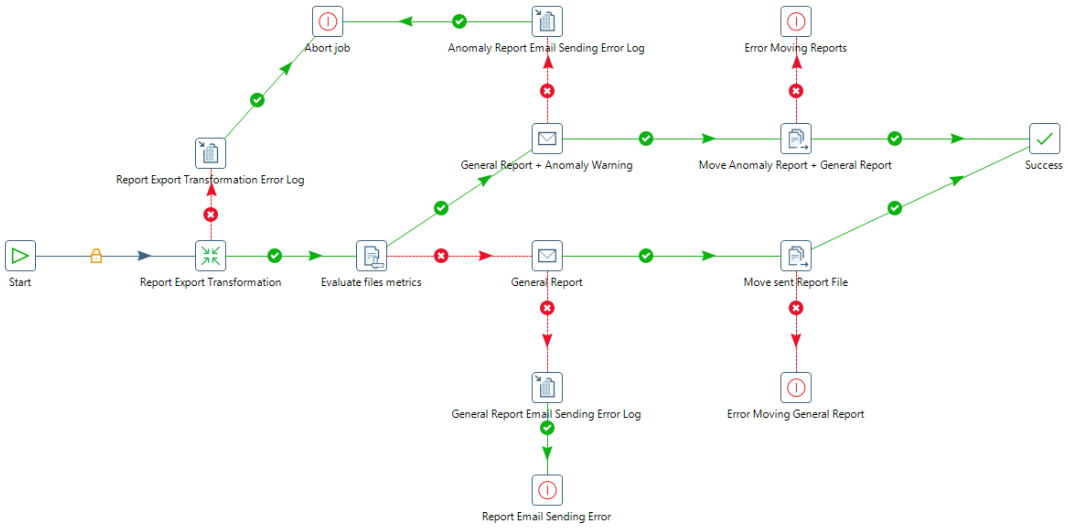


Figura 6 - Diagrama de fluxo Job de Exportação

1. Geração Analítica e Avaliação de Condições

- **Report Export Transformation**: Executa a transformação analítica que agrega os dados da base de dados e gera os ficheiros físicos de resumo de produção e métricas de queima. Em caso de falha de execução, o erro é desviado para Report Export Transformation Error Log e interrompe o processo no nó Abort job.
- **Evaluate files metrics**: Analisa as métricas presentes nos ficheiros gerados (avaliando, por exemplo, o tamanho, número de linhas ou indicadores de queima como excesso de quebras e violações de temperatura máxima) para decidir a rota de comunicação.

2. Ramo de Alerta de Anomalias (Caminho Verde / Sucesso na Condição):

- **General Report + Anomaly Warning**: Se forem apuradas anomalias térmicas ou de qualidade no ciclo de queima, este step de envio de correio eletrónico (SMTP) remete um e-mail de alerta, anexando tanto o relatório geral como o alerta detalhado de anomalias.
- **Move Anomaly Report + General Report**: Move com sucesso ambos os ficheiros para a pasta de histórico de relatórios enviados, finalizando no nó Success.
- *Tratamento de Exceções:* Falhas no envio de e-mail ativam o Anomaly Report Email Sending Error Log e depois Abort job, enquanto problemas na movimentação de ficheiros ativam o nó Error Moving Reports.

3. Ramo de Operação Normal (Caminho Vermelho / Falso na Condição):

- **General Report**: Caso não existam ocorrências críticas de anomalia, o sistema encaminha exclusivamente o relatório de produção geral e indicadores habituais de custos aos destinatários.
- **Move sent Report File**: Concluído o envio do correio eletrónico, o relatório expedido é transferido para o arquivo permanente, alcançando o nó Success.
- *Tratamento de Exceções:* Erros no envio acionam o General Report Email Sending Error Log e terminam no nó de paragem Report Email Sending Error; anomalias ao arquivar o relatório são sinalizadas pelo nó Error Moving General Report.

5.3. Main Job

O Main Job funciona como o ponto de entrada e orquestrador de topo de todo o ecossistema ClaySense, sendo o elemento disparado pelo agendador de tarefas (scheduler) da infraestrutura. A sua responsabilidade é coordenar sequencialmente os dois grandes blocos do sistema: em primeiro lugar, a ingestão, validação e persistência dos dados de produção através do sub-job Data Staging Pipeline; em segundo lugar, concluído o carregamento com sucesso, o processamento analítico e distribuição da informação no sub-job Generate Report. Operando segundo o princípio fail-fast, qualquer falha crítica num dos blocos desvia a execução para logs de diagnóstico dedicados e termina imediatamente o processo no nó Abort job, impedindo a criação de relatórios com dados inconsistentes ou desatualizados. Na seguinte Figura 7 é observável a simplicidade de um job principal:

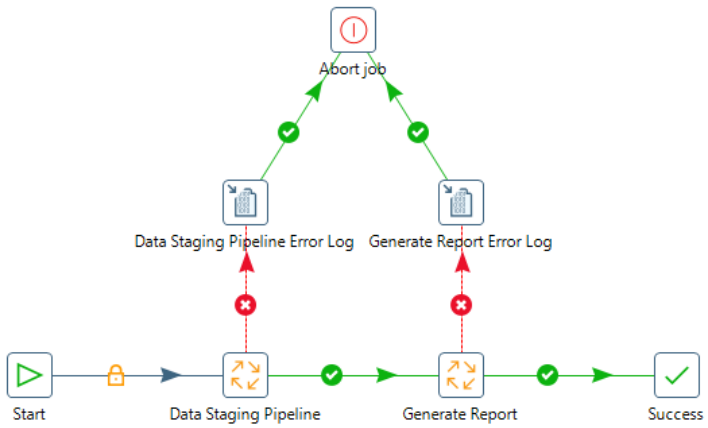


Figura 7 - Diagrama do fluxo - MainJob

Início e Execução do Ciclo de Dados (Start - Data Staging Pipeline):

- O job arranca no nó Start e executa como primeira tarefa o sub-job Data Staging Pipeline.
- É neste primeiro bloco que se validam as ligações ao PostgreSQL (NeonDB), a presença física dos ficheiros (CSV, XML, JSON) e se executam as duas transformações nucleares (Data Preparation e Production Model) com arquivo posterior dos ficheiros fonte.
- *Tratamento de Exceções:* Se o Data Staging Pipeline falhar (caminho vermelho com ×), o fluxo é intercetado pelo nó Data Staging Pipeline Error Log, que regista a falha de ingestão e encaminha para o Abort job, abortando o processo antes de tentar gerar relatórios sobre uma base de dados não atualizada.

2. Execução da Camada Analítica (Generate Report):

- Uma vez concluído o carregamento e arquivo de dados com êxito, o job avança para a chamada do sub-job Generate Report (que no diagrama detalhado corresponde ao Report Export Job).
- Este sub-job executa a transformação de agregação, avalia a ocorrência de anomalias térmicas e expede os e-mails com os relatórios devidos (aviso com anomalias ou relatório geral).
- *Tratamento de Exceções:* Se a extração analítica ou a comunicação SMTP falhar, o erro ativa o nó Generate Report Error Log e desvia igualmente para o Abort job.

3. Finalização Global (Success):

- O nó Success só é alcançado se ambos os sub-jobs completarem as respetivas tarefas sem qualquer exceção não tratada, confirmando que a base de dados de produção foi alimentada e que a gestão fabril foi notificada com sucesso

6.Visualização Analítica com Grafana

De forma a permitir que a administração e os responsáveis de produção de visibilidade em tempo real sobre a operação, configurou-se uma camada de visualização analítica através da plataforma **Grafana**, conectada diretamente à base de dados relacional PostgreSQL (NeonDB). O painel de controlo (*dashboard*) foi estruturado para consolidar os dados processados pelo pipeline ETL, permitindo correlacionar indicadores de produtividade, eficiência energética e estabilidade térmica dos fornos.

Main Dashboard

Indicadores Chave de Desempenho (KPIs) - A secção superior do painel consolida o volume produtivo imediato. O destaque analítico recai sobre o cálculo do "Custo por Peça Aprovada" (€0.764), que comprova o sucesso do pipeline de ETL na integração de fontes heterogéneas, correlacionando o consumo energético dos fornos com o desperdício (5,99% de taxa de defeito) e a produção válida.

Análise Temporal de Produção - O gráfico de barras emparelhadas materializa a persistência histórica assegurada pela base de dados PostgreSQL. A comparação diária entre a produção válida e as peças rejeitadas permite aos gestores da linha de produção identificar tendências de curto e médio prazo, bem como avaliar a estabilidade geral do processo de cozedura da cerâmica.



Figura 8 - Preview do Main Dashboard no Grafana

Controlo de Qualidade Operacional - A avaliação da "Taxa de Defeito por Oleiro" introduz a componente humana na análise de dados. A aplicação de formatação condicional (escala de cores entre o verde, amarelo e vermelho) nativa do Grafana permite a identificação instantânea de desvios na qualidadedo trabalho manual, suportando intervenções direcionadas para formação ou reajuste de equipas.

Link de acesso ao Main Dashboard:

- https://claysense.grafana.net/public-dashboards/0a6430ff0ae147e8b8e4455f1f19cdc8

Dashboard de Fornos, Custos & Energia

O dashboard de Fornos, Custos & Energia cruza a telemetria térmica com os gastos de consumo, demonstrando a capacidade da plataforma em identificar ineficiências operacionais. O painel evidencia que o Forno B consome substancialmente mais gás, gerando custos operacionais superiores aos do Forno A.



Figura 9 - Preview do Dashboard de Fornos e Custos no Grafana

A correlação de dados revela ainda que temperaturas de cozedura superiores a 1000°C resultam num aumento acentuado da taxa de defeito. Esta visualização valida o objetivo do projeto, entregando aos gestores insights diretos para otimizar os parâmetros térmicos e reduzir o desperdício industrial.

- Dashboard de Anomalias e Custos
  https://claysense.grafana.net/public-dashboards/d7bf2601fa43473f8a0b97ed10a40943

7.Vídeo com demonstração (QR Code)

O QR Code e a hiperligação abaixo encaminham para o vídeo de demonstração do fluxo completo da aplicação:

Link direto: https://www.youtube.com/watch?v=VY8UAlYBfE4

Índice da demonstração:

- 00:00 – 00:14 – Fluxo do Node-RED
- 00:14 – 00:33 - Fluxo de jobs no PDI
- 00:33 – 00:45 – Fluxo de transformações no PDI
- 00:45 – 00:46 – Confirmação de Envio de Email Automatizado
- 00:46 – 00:59 – Exportação de Relatórios Gerais e de Anomalias
- 00:59 - 01:10 - Visualização de métricas no Grafana

8. Conclusão

O projeto ClaySense cumpriu o objetivo de conceber e implementar uma arquitetura de integração de dados capaz de modernizar o controlo operacional na indústria cerâmica, preenchendo a histórica dependência de métodos tradicionais. Através da orquestração de um pipeline ETL robusto e tolerante a falhas no Pentaho Data Integration, suportado pela emulação IoT via Node-RED e MQTT, demonstrou-se a viabilidade de automatizar a recolha e o cruzamento da telemetria dos fornos com os registos de fabrico e os tarifários dinâmicos de energia. A centralização dos dados num modelo relacional normalizado em PostgreSQL, aliada à camada de inteligência analítica no Grafana, fornece à administração fabril indicadores rigorosos e imediatos sobre o rendimento de peças aprovadas, a estabilidade dos ciclos térmicos e o impacto financeiro de cada fornada.

Como perspetivas de desenvolvimento futuro, a evolução do sistema deverá contemplar a integração de modelos de *Machine Learning* para análise preditiva, permitindo antecipar anomalias de cozedura e otimizar as curvas de temperatura antes da ocorrência de quebras. A contentorização integral da infraestrutura seria uma melhoria (utilizando tecnologias como Docker), para garantir uma escalabilidade fluida em ambientes de produção industrial, bem como a expansão do módulo de notificações de anomalia para plataformas de mensagens instantâneas utilizadas diretamente pelos operadores de fábrica.

8. Referências bibliográficas

- Eclipse Foundation. (s.d.). *Eclipse Mosquitto: An open source MQTT broker*. Recuperado de https://mosquitto.org/
- Grafana Labs. (s.d.). *Grafana: The open observability platform*. Recuperado de https://grafana.com/
- Hitachi Vantara. (s.d.). *Pentaho Data Integration (Kettle)*. Recuperado de https://www.hitachivantara.com/
- Neon. (s.d.). *Neon: Serverless Postgres*. Recuperado de https://neon.tech/
- OpenJS Foundation. (s.d.). *Node-RED: Low-code programming for event-driven applications*. Recuperado de https://nodered.org/
- PostgreSQL Global Development Group. (s.d.). *PostgreSQL: The World's Most Advanced Open Source Relational Database*. Recuperado de https://www.postgresql.org/
- REN - Redes Energéticas Nacionais. (s.d.). *Dados do Sistema Elétrico e Gás Natural*. Recuperado de https://datahub.ren.pt/